

Problématique finale

How do S, M and L segment sequences differ across major Orthohantavirus species, and can sequence-level features support molecular classification and epidemiological interpretation?

En français :

Comment les séquences des segments S, M et L diffèrent-elles entre les principales espèces d'Orthohantavirus, et est-ce que leurs caractéristiques moléculaires peuvent soutenir la classification virale et l'interprétation épidémiologique ?

Architecture du projet

1. Comprendre le hantavirus biologiquement

Comprendre et expliquer:

- famille **Hantaviridae** ;
- virus enveloppé ;
- génome **ARN simple brin négatif segmenté** ;
- trois segments : **S, M, L** ;
- segment **S** : nucléoprotéine ;
- segment **M** : glycoprotéines virales ;
- segment **L** : polymérase ARN-dépendante.

Les longueurs attendues sont importantes pour notre audit : le segment **S** fait environ **1–3 kb**, le segment **M** environ **3,2–4,9 kb**, et le segment **L** environ **6,8–12 kb**. Ça nous servira à repérer les séquences incomplètes, trop courtes ou suspectes. ([ViralZone](#))

2. Construire un vrai dataset moléculaire

Source principale : **NCBI Virus / GenBank**.

NCBI Datasets permet de télécharger des packages viraux contenant des séquences génomiques, des CDS, des protéines et un fichier de métadonnées en JSON Lines. C'est exactement ce qu'il nous faut pour faire une analyse propre. ([NCBI](#))

Je propose de récupérer au minimum :

Virus / espèce

Intérêt

Puumala virus	Europe, HFRS/nephropathia epidemica
Hantaan virus	Asie, HFRS classique
Seoul virus	Réservoir rat, distribution plus urbaine
Sin Nombre virus	Amérique du Nord, HPS
Andes virus	Amérique du Sud, HPS, transmission interhumaine limitée

On ajoutera **HantaNet** comme source secondaire/validation, parce que l'outil s'appuie sur des datasets de référence GenBank et propose des données de séquence/métadonnées standardisées pour les hantavirus. ([PubMed](#))

3. Nettoyer et auditer les séquences

Là, on fait le vrai travail bioinfo.

On vérifiera :

- nombre de séquences par espèce ;
- segment : S, M ou L ;
- longueur des séquences ;
- pourcentage GC ;
- bases ambiguës **N** ;
- doublons ;
- séquences trop courtes ;
- séquences complètes vs partielles ;
- métadonnées disponibles : pays, hôte, date, accession, souche.

C'est important parce qu'un dataset moléculaire peut être "vrai" mais quand même inutilisable si trop de séquences sont partielles ou mal annotées.

4. Analyses moléculaires

On peut ensuite faire plusieurs niveaux d'analyse.

Niveau simple mais propre

- distribution des longueurs par segment ;
- GC content par espèce ;
- fréquence des nucléotides ;
- k-mers ;
- PCA/UMAP sur k-mers ;
- classification des espèces à partir des signatures de séquence.

Niveau bioinfo avancé

- alignement multiple par segment ;
- conservation des positions ;
- distances génétiques ;
- arbre phylogénétique par segment ;
- comparaison des arbres S/M/L ;
- recherche de discordances pouvant suggérer réassortiment ou différences d'évolution entre segments.

Les hantavirus ont un génome segmenté, donc comparer séparément S, M et L est justement beaucoup plus intéressant que de traiter toutes les séquences comme un bloc unique.

5. Relier moléculaire, clinique et épidémiologie

Ensuite on connecte la biologie aux conséquences santé.

Les hantavirus peuvent causer notamment **HPS** / syndrome pulmonaire à hantavirus et **HFRS** / fièvre hémorragique avec syndrome rénal. Le CDC rappelle aussi que les hantavirus sont principalement transmis par les rongeurs, et qu'**Andes virus** est le seul type connu pour une transmission interhumaine, généralement limitée aux contacts proches. ([CDC](#))

On pourra donc interpréter les groupes moléculaires avec :

- syndrome associé : HPS vs HFRS ;
- zone géographique ;
- réservoir animal ;
- segment viral ;
- proximité génétique ;
- espèce virale.

Ce qu'on garde de Kaggle

Les datasets Kaggle ne seront pas jetés, mais on les met à leur vraie place.

Dataset	Utilisation
Kaggle detection dataset	Audit ML, data leakage, modèle clinique pédagogique
Kaggle global epidemiology	Visualisation épidémiologique, cartes, pays, cas, décès
NCBI / GenBank	Cœur du projet moléculaire
HantaNet	Validation / dataset curé

CDC / OMS / PAHO / articles Contexte clinique et santé publique

Comme ça, ton projet devient beaucoup plus sérieux : tu ne dépends pas d'un seul dataset douteux.

Pipeline concret du projet

Étape 1 — Data collection

Télécharger les séquences depuis NCBI :

```
datasets download virus genome taxon Orthohantavirus \
--include genome,protein,cds,biosample \
--filename orthohantavirus.zip
```

Ou espèce par espèce :

```
datasets download virus genome taxon "Orthohantavirus puumalaense" \
--include genome,protein,cds,biosample \
--filename puumala.zip
```

Même chose pour Andes, Seoul, Hantaan et Sin Nombre.

Étape 2 — Parsing

Avec Python/Biopython :

- lire les FASTA ;
- extraire accession, longueur, description ;
- relier les séquences aux métadonnées ;
- identifier le segment S/M/L ;
- créer un tableau propre.

Table finale attendue :

accession	species	segment	length	gc_content	host	country	collection_date
-----------	---------	---------	--------	------------	------	---------	-----------------

Étape 3 — EDA moléculaire

Graphiques :

- nombre de séquences par espèce ;

- nombre de séquences par segment ;
- longueurs S/M/L ;
- GC content par espèce ;
- pays les plus représentés ;
- années de collecte.

Étape 4 — Analyse de séquence

Features :

- longueur ;
- GC content ;
- fréquences A/T/G/C ;
- k-mers 3, 4 ou 5 ;
- éventuellement codon usage sur les CDS.

Puis :

- PCA ;
- clustering ;
- classification espèce/segment ;
- interprétation des features.

Étape 5 — Alignement et phylogénie

Pour chaque segment :

- alignement multiple ;
- distance matrix ;
- arbre phylogénétique ;
- comparaison des espèces.

On peut commencer simple avec un arbre neighbor-joining, puis aller plus loin si nécessaire.

Livrables finaux

Je viserais ces livrables :

1. **Notebook 1 — Dataset audit**
 - audit Kaggle detection ;
 - détection de leakage ;
 - comparaison avec vraies données moléculaires.
2. **Notebook 2 — Molecular dataset construction**
 - téléchargement NCBI ;
 - parsing FASTA ;

- nettoyage métadonnées.
- 3. **Notebook 3 — Molecular analysis**
 - GC content ;
 - longueurs ;
 - k-mers ;
 - PCA/clustering ;
 - classification.
- 4. **Notebook 4 — Phylogeny**
 - alignements ;
 - distances ;
 - arbres par segment.
- 5. **Notebook 5 — Epidemiological interpretation**
 - HFRS vs HPS ;
 - géographie ;
 - Andes/Sin Nombre/Puumala/Hantaan/Seoul ;
 - discussion santé publique.

Titre possible du projet

Segmented Genomes, Molecular Signatures and Epidemiological Patterns of Orthohantaviruses